

RDBMS Projekt

Autor: Martin Morávek

Kontaktní údaje: moravek2@spsejecna.cz

Datum vypracování: 29.03.2026

Název školy: Střední průmyslová škola elektrotechnická, Praha 2, Ječná 30

Jedná se o školní projekt

Specifikace požadavků:

Projekt implementuje klasifikátor druhů motýlů na základě fotografií pomocí hlubokého učení.

Obsahuje:

- trénovací skript: `analyser.py`
- inferenční skript: `main.py`

Model využívá:

- konvoluční neuronovou síť (CNN)
- transfer learning (EfficientNetV2S)
- dvoufázový trénink (hlava + fine-tuning)

Architektura aplikace:

Aplikace je rozdělena na dvě hlavní části:

1. Trénovací část

- načítání dat ze složky
- automatické určení tříd ze jmen souborů
- rozdělení dat (train / validation / test)
- trénování modelu ve dvou fázích:
 - fáze 1: trénování klasifikační hlavy
 - fáze 2: jemné doladění backbone sítě
- ukládání modelu do .keras souboru

2. Inferenční část

- načtení uloženého modelu
- klasifikace jednotlivých obrázků
- použití Test-Time Augmentation (TTA) pro vyšší přesnost

Běh aplikace:**Trénování modelu:**

1. Spuštění analyser.py
2. Načtení obrázků ze složky
3. Automatické vytvoření tříd
4. Rozdělení dat na trénovací, validační a testovací
5. Trénování modelu:
 - fáze 1 (head training)
 - fáze 2 (fine-tuning)
6. Vyhodnocení modelu
7. Uložení modelu do souboru

Inferenční běh:

1. Spuštění main.py
2. Načtení modelu
3. Vložení obrázku
4. Výstup: predikovaný druh motýla

Import / export:**Import:**

- obrázky ve formátu .jpg, .jpeg, .png

Export:

- natrénovaný model (.keras)

Konfigurace aplikace:

Konfigurace se nachází přímo v horní části trénovacího skriptu.

Hlavní parametry:

- DATA_DIR – cesta ke složce s obrázky
- IMG_SIZE – rozlišení (doporučeno 384×384)
- BATCH_SIZE – velikost batch (doporučeno 64+)
- MODEL_PATH – název výstupního modelu
- VAL_SPLIT – validační data (např. 15 %)
- TEST_SPLIT – testovací data (např. 10 %)

Trénovací parametry:

- P1_LR, P2_LR – learning rate
- P1_MAX_EPOCHS, P2_MAX_EPOCHS
- WARMUP_EPOCHS
- LABEL_SMOOTHING
- N_FINE_TUNE

Použitá rozhraní, knihovny a závislosti:**Programovací jazyk:**

- Python 3.11+

Knihovny:

- TensorFlow / Keras – hluboké učení
- scikit-learn – metriky, preprocessing
- NumPy – numerické operace
- Matplotlib – grafy
- Seaborn – konfuzní matice
- h5py – ukládání modelu

Právní a licenční aspekty:

- Projekt je studentský
- Nepoužívá komerční software
- Využívá open-source knihovny
- Model může být dále rozšiřován

Instalace a spuštění:**Požadavky:**

- Python 3.11+
- (doporučeno) NVIDIA GPU

Postup:

1. Nainstalovat Python
2. Nainstalovat nejnovější verze knihoven tensorflow, keras, scikit-learn, numpy, matplotlib, seaborn
3. Připravit dataset (složka s motýli)
4. Spustit analyzátor
5. Po natrénování dat spustit samotný program pro rozpoznávání

Chybové stavy a jejich řešení:

Nestabilní trénování

Příčina:

- malý batch size

Řešení:

- zvýšit BATCH_SIZE

NaN loss

Příčina:

- příliš vysoký learning rate

Řešení:

- snížit P1_LR

Špatné predikce

Příčina:

- špatné pořadí tříd (CLASS_NAMES)

Řešení:

- zachovat stejné pořadí jako při trénování

Databáze / struktura dat:

Dataset je uložen ve složce, fotografie mají následující název: `NázevDruhu_informaceNavíc`, minimálně 2 obrázky na druh

Síť a externí služby:

- aplikace nevyužívá síťové služby
- nevyžaduje server
- běží lokálně

Hardware a další služby:**Minimum:**

- CPU (pomalejší trénování)

Doporučeno:

- NVIDIA GPU (2× rychlejší trénování díky mixed precision)

Poznámky:

- model využívá EfficientNetV2S
- používá transfer learning
- podporuje nevyvážená data (class weights)
- využívá moderní techniky:
 - mixed precision
 - cosine decay learning rate
 - label smoothing
 - TTA (Test-Time Augmentation)

8/8  19s 2s/step - accuracy: 0.9545 - loss: 0.6754

Test accuracy : 0.9545

Test loss : 0.6754

8/8  23s 2s/step